

Silicon Sampling 實作教學手冊

Argyle et al. (2023) Study 2 複製：從原始資料到驗證

ANES 2020 × GPT-5.6 × GABRIEL



作者：羅軒濤

草稿 v0.1 (內部教學用)

思多葛市場研究

目錄

目錄.....	2
一、這份手冊在講什麼.....	3
二、資料來源與變數手冊.....	4
2.1 資料來源.....	4
2.2 讀懂代碼：通用規則.....	4
2.3 本實驗使用的 11 個變數.....	4
三、資料整理規格.....	6
四、Backstory.....	6
五、Argyle 補充材料的問題清單.....	8
六、我們的必要偏離 (Deviation Log)	10
七、實驗執行紀錄.....	10
7.1 Pilot 的兩個發現.....	10
7.2 正式生成規格 (凍結)	10
八、驗證方法與結果.....	12
8.1 個體層驗證 (照論文方法)	12
8.2 分布層驗證 (照論文 Study 3 方法：Cramér's V)	12
8.3 延伸觀察 (非論文方法，本次新增)	12
8.4 GABRIEL 對照：換任務框架.....	13
九、結論與使用守則.....	14
附錄：程式檔案清單與執行順序.....	14

一、這份手冊在講什麼

本手冊記錄一次完整的「LLM 模擬受訪者」(silicon sampling) 實作：大部分複製 Argyle et al. (2023) 發表於 Political Analysis 的〈Out of One, Many〉Study 2，用美國全國選舉研究 (ANES) 2020 年資料中的八項背景變數建構第一人稱 persona，讓語言模型模擬每位受訪者回答「2020 年總統大選投給誰」，再與真人的實際回答比對。原論文使用 GPT-3，本次複製使用 2026 年的 GPT-5.6，因此嚴格來說是「概念複製」(conceptual replication)：方法照抄，模型換代。

在三角色框架中，本實驗以 LLM 作為模擬受訪者 (Role 3) 為主體，最後以 Role 1 (LLM 作為測量工具，GABRIEL) 做任務框架對照。全流程如下：

- 步驟一 原始資料整理：從 ANES 2020 原始檔裁出 11 個欄位 (8,280 → 5,441 人)
- 步驟二 Pilot (20 人)：測試 API 可行性，發現模型拒答問題並修正
- 步驟三 正式生成 (1,000 人)：機率讀出法產生 silicon 投票
- 步驟四 驗證：個體層 (一致率) 與分布層 (Cramér's V)
- 步驟五 GABRIEL 對照：同資訊、換任務框架 (第三人稱分類)

手冊同時收錄本次在 Argyle 補充材料中發現的問題清單 (第五章) 與我們的必要偏離 (第六章) ——這兩章是「複製研究為什麼一定要讀 replication code」的實例教材。

二、資料來源與變數手冊

2.1 資料來源

ANES (American National Election Studies) 是美國歷史最悠久的全國選舉調查 (1948 年迄今) ，由密西根大學與史丹佛大學執行，選前選後兩波訪問，資料公開。本次使用 2020 年時間序列研究 (Time Series Study) ：

- 原始檔：anes_timeseries_2020_csv_20220210.csv (2022 年 2 月 10 日釋出版)
- 全樣本 8,280 人 = 2020 年新抽樣 5,441 人 + 2016-2020 連續樣本 (panel) 2,839 人
- 官方 codebook 為所有變數意義的最終依據：electionstudies.org

2.2 讀懂代碼：通用規則

ANES 的欄位幾乎都是數字代碼。正值通常是有效答案，負值是各種「沒有答案」的原因。常見負值代碼如下 (各變數略有差異，以 codebook 為準) ：

代碼	意義
-9	拒答 (Refused) ——受訪者拒絕回答這一題
-8	不知道 (Don't know)
-7	訪問不完整，資料刪除 (多見於選後題)
-6	沒有接受選後訪問 (後測題常見的大宗缺失)
-5	訪問中斷 (Breakoff)
-1	不適用 (Inapplicable) ——因前題答案跳過此題，例如沒投票的人不會被問投給誰

三個重要觀念：

- 負值不是錯誤，是資訊。它告訴你「為什麼沒有答案」。清資料時原樣保留，不要急著刪。
- 有些正值也有特殊意義：如 V201200 的 99 = 「沒想過」是有效答案；V201507x 的 80 = 「80 歲 (含) 以上」的截尾值。
- 變數編號規則：V201 開頭 = 選前訪問 (pre) ，V202 開頭 = 選後訪問 (post) 。後測題天生多一成左右的缺失 (選後流失) 。

2.3 本實驗使用的 11 個變數

依用途分三層：管理用 2 個、persona 條件變數 8 個 (進 backstory 模板) 、結果變數 1 個。

變數	名稱 / 用途	數值代碼與意義
V200001	受訪者編號 (管理用)	每人唯一的流水號。所有資料合併都靠它。
V200003	樣本類型 (篩選用)	1 = 2020 年新抽樣 (保留) 2 = 2016-2020 連續樣本 panel (排除)
V201549x	種族 / 族裔 (條件變數)	官方編碼：1 = 白人 (非西語裔)、2 = 黑人 (非西語裔)、3 = 西語裔、4 = 亞裔 / 太平洋島民、5 = 美洲原住民 / 其他、6 = 多重種族 注意：Argyle 程式碼的對照表用錯版本，詳見第五章問題 P3。
V202022	與親友討論政治 (條件變數，後測)	1 = 會討論、2 = 從不討論
V201200	意識形態自我定位 (條件變數)	1 = 極自由派 ... 4 = 中間 ... 7 = 極保守派 99 = 「沒想過」——有效答案，不是缺失！這些人保留在樣本，backstory 省略意識形態句。
V201231x	政黨認同 7 點 (條件變數)	1 = 堅定民主黨、2 = 溫和民主黨、3 = 獨立偏民主黨、4 = 純獨立、5 = 獨立偏共和黨、6 = 溫和共和黨、7 = 堅定共和黨
V201452	是否參加宗教活動 (條件變數)	1 = 有參加、2 = 沒有參加
V201507x	年齡 (條件變數)	18-79 = 實際歲數；80 = 80 歲 (含) 以上一律記 80 (截尾) 負值 = 缺失。注意 Argyle 程式碼對此欄不檢查，詳見第五章問題 P4。
V201600	性別 (條件變數)	1 = 男性、2 = 女性
V202406	政治興趣 (條件變數，後測)	1 = 非常有興趣、2 = 有些興趣、3 = 不太有興趣、4 = 完全沒興趣
V202110x	2020 總統投票對象 (結果變數)	1 = Biden、2 = Trump、3 = Jorgensen (自由黨)、4 = Hawkins (綠黨)、5 = 其他候選人 負值 = 沒投票或沒回答。比對階段只用 1 與 2。

三、資料整理規格

整理流程只有五步：

- 讀入原始檔 (8,280 人)
- 唯一的樣本排除：V200003 = 2 (panel) → 剩 5,441 人
- 只保留上述 11 個欄位，所有原始代碼原封不動
- 盤點結果變數分布 (Biden 2,297 / Trump 1,608 / 第三方 108 / 負值 1,428)
- 存成凍結分析檔 anes2020_study2_frozen.csv

三條紀律 (也是最常被問的三個問題)

一、為什麼不刪缺失值？ Argyle 的規則是「某變數缺失，就在 persona 描述裡省略那一句，人保留」。所以不做 listwise deletion——如果照直覺刪掉「任一變數缺失」的人，樣本會少一千多人，而且刪掉的是特定類型的人 (例如 812 個意識形態填「沒想過」的人)，整個分布都會歪。

二、為什麼生成階段不排除沒投票的人？ Argyle 是全部 5,441 人都生成 persona 並查詢，比對答案時才自然縮小到有投票紀錄者。樣本定義照抄，不加自己的裁量。

三、我們的 5,441 對論文的 5,442 差一筆，怎麼辦？ 資料版本差異 (Argyle 用 2021 年早期釋出版，我們用 2022 年 2 月版)，佔比 0.018%，對任何統計量無實質影響。記入偏離記錄，不要為了湊數去動資料——那才是真正的方法論錯誤。

四、Backstory

每位受訪者的變數值，透過固定模板組裝成一段第一人稱英文自我介紹 (backstory)。句子順序固定，變數缺失則整句省略。對照表如下 (照抄 Argyle 補充材料的 anes2020.py，含其大小寫不一致等原樣保留)：

變數	模板句 (依組裝順序)
V201549x	Racially, I am < white / black / asian / native American / hispanic > .
V202022	I like to discuss politics with my family and friends. 或 I never discuss politics with my family or friends.
V201200	Ideologically, I am < extremely liberal ... extremely conservative > .
V201231x	Politically, I am < a strong democrat ... a strong Republican > .
V201452	I attend church. 或 I do not attend church.
V201507x	I am < 歲數 > years old. (數值直接代入)

變數	模板句 (依組裝順序)
V201600	I am a < man / woman > .
V202406	I am < very / somewhat / not very / not at all > interested in politics.

組裝完的 backstory 之後接上固定的提問句 (2020 年版特有，含候選人提示)：

"In the 2020 presidential election, Donald Trump is the Republican candidate, and Joe Biden is the Democratic candidate, and I voted for"

完整範例

I like to discuss politics with my family and friends. Ideologically, I am liberal. Politically, I am a strong democrat. I do not attend church. I am 20 years old. I am a man. I am very interested in politics. In the 2020 presidential election, Donald Trump is the Republican candidate, and Joe Biden is the Democratic candidate, and I voted for

(這位受訪者的種族欄是缺失值，所以整段沒有 Racially 那一句——這就是「缺句省略、人保留」規則的實際樣貌。)

五、Argyle 補充材料的問題清單

複製過程中我們逐行核對了論文正文、補充材料與其 replication code，發現以下問題。每一條都附「我們的處置」。總原則：程式碼與正文衝突時，以程式碼為準（因為發表的數字是程式碼跑出來的）；已發現的 bug 原則上照抄（完全複製的目的是與原論文數字可比），但記錄在案並在解讀時修正。

P1 正文的變數編號筆誤

補充材料正文寫「討論政治」用 V201452——但 V201452 是宗教參與，同一句已用過。實際程式碼用的是 V202022（選後的討論政治題）。因此以程式碼為準，採 V202022。

P2 政治興趣的變數無法從正文判定

ANES 2020 有兩個相近題目（V201005 注意政治 / V202406 政治興趣），正文描述無法區分。程式碼定案：V202406。教訓：凍結變數清單之前，必須先取得 replication code。

P3 種族編碼錯置（本次新發現，影響最大）

ANES 在 2020 年更改了種族摘要變數的編碼順序，但 Argyle 的 2020 程式碼沿用了 2016 年的對照表。官方 codebook 與其程式碼的對照如下：

代碼	ANES 2020 官方意義	Argyle 模板寫成	全樣本佔比
1	白人（非西語裔）	white（正確）	72.9%
2	黑人（非西語裔）	black（正確）	8.9%
3	西語裔	asian（錯置）	9.3%
4	亞裔 / 太平洋島民	native American（錯置）	3.5%
5	美洲原住民 / 其他	hispanic（錯置）	2.1%
6	多重種族	（不在對照表，整句省略）	3.3%

後果：約 15% 受訪者的 backstory 種族句貼錯標籤（西語裔被描述成亞裔、亞裔被描述成原住民、原住民被描述成西語裔），另有 3.3% 多重種族者種族句無聲消失。白人與黑人（合計約 82%）不受影響，因此整體結果變動有限，但論文 Table 9 的「Hispanics」列，實際上比的是貼錯標籤的人群。

處置：本次複製照抄其對照表（維持與論文數字可比），但所有涉及種族子群體的解讀都須加註修正標籤。這是「模板程式碼也是測量工具的一部分」的最佳教學案例——一行複製貼上的疏忽，直接改寫了一成五 persona 的身分。

P4 年齡欄不做有效性檢查

程式碼對年齡採「數值直接代入」且不檢查，因此年齡缺失者（代碼 -9）的 backstory 會出現 "I am -9 years old." 這種句子——2020 年約 256 人。處置：照抄（原論文數字含此 bug），記錄在案。

P5 州別變數的正文與程式碼矛盾

正文明言 2020 年分析不含州別（當時資料未釋出），但程式碼保留了州別模板段。合理解讀是該欄位當時無有效值、句子自動省略。處置：我們直接排除州別，確保與論文 Table 9 的 2020 數字對齊。

P6 查詢數 5,442 與現行資料的 5,441

差一筆，歸因於 ANES 資料版本差異（詳第三章）。

P7 其他品質訊號

補充材料有多處打字錯誤（如年份寫成 20112、查詢數寫成 1,1471），2016 年的 token set 收錄了語意模糊的詞（如 senator 歸給 Clinton）。

六、我們的必要偏離 (Deviation Log)

以下是我們無法避免、或有明確理由選擇的偏離。每一條在報告成果時都須揭露。

編號	偏離內容	理由
D1	模型：GPT-3 davinci → GPT-5.6 (reasoning effort = none)	GPT-3 已下架。本次因此屬概念複製；「2026 模型能否重現 2023 結果」本身即為研究問題。
D2	介面：Completion API → Chat API，加一句中性續寫指令 "Complete the following text."	Chat 模型會把任務誤讀成「猜使用者投票」而拒答；此指令僅還原原本的續寫框架，經 pilot 驗證不改變任何原本會作答者的答案。
D3	logprobs：前 100 名 → 前 5 名	現行 API 上限為 5。對本任務影響極小（候選人 token 幾乎必然在前幾名）。
D4	拒答處理：前 5 名無候選人 token → 編碼為缺失，不重試	GPT-3 無拒答現象，這是 2026 對齊模型的新行為；升級指令強度會引導內容，故如實記錄。後續發現拒答本身有訊號（第八章）。
D5	樣本：全量 5,441 → 隨機抽 1,000 (種子 42)	成本考量。整體一致率不受影響，但小子群體（如純獨立選民）數字波動較大。

七、實驗執行紀錄

7.1 Pilot 的兩個發現

正式跑之前先抽 20 人測試 (pilot)，立刻抓到兩件事：

- 技術面：logprobs 參數可用但上限是 5 (不是拒絕提供) → 偏離 D3。
- 行為面：模型會拒答 (「我無法猜測你投給誰」)，且拒答不是隨機的——集中在政黨認同弱的 persona (獨立選民、leaner)，強認同者全數作答。這是對齊訓練造成的系統性缺失，GPT-3 沒有此現象。

修正：加入續寫指令 (D2) 後做 2×2 驗證——拒答從 8 人降至 1 人，且原本會作答的 12 人答案全數不變，證明指令乾淨、未引導內容。

7.2 正式生成規格 (凍結)

- 1,000 人 (種子 42) × 每人一次查詢，機率讀出法

- 讀首 token 前 5 名，落在 Trump token set (donald / trump / republican / conservative) 與 Biden token set (joe / joseph / biden / democrat / democratic / liberal) 的機率各自加總後歸一化
- 機率 > 0.5 判為投 Trump (Argyle 的二分法) ；前 5 名無候選人 token = 拒答缺失
- 斷點續跑：每完成一人立即落盤，中斷重跑不重複計費

結果：有效機率 952 人、拒答 48 人 (4.8%) 、API 失敗 0。

八、驗證方法與結果

8.1 個體層驗證 (照論文方法)

可比對樣本 = 真人投兩黨且模型有答案者，n = 726。

指標	我們 (GPT-5.6)	Argyle (GPT-3, 2020)
Proportion agreement	0.864	0.89
Cohen's kappa	0.717	0.77
強政黨認同者 PA	0.98	0.97
純獨立選民 PA	0.46	0.53

判讀：整體一致率與分層形狀（強認同高、獨立低）皆重現，複製成功。

8.2 分布層驗證 (照論文 Study 3 方法：Cramér's V)

Cramér's V 衡量「知道 A 能幫你多猜中 B 多少」（0 到 1）。對每個背景變數 × 投票，真人資料算一次、silicon 資料算一次，並排比較——這是 Argyle 對「模型是否裝著人群分布」的操作型檢驗。

變數 × 投票	真人世界 V	Silicon 世界 V	差 (真人 – silicon)
政黨認同	0.83	0.89	-0.05
意識形態	0.77	0.84	-0.07
宗教參與	0.24	0.24	+0.01
政治興趣	0.13	0.08	+0.05
種族 (依模板標籤)	0.21	0.22	-0.01
談政治	0.03	0.03	0.00
性別	0.02	0.10	-0.09
年齡 (分組)	0.11	0.13	-0.02

判讀：八個變數有六個幾乎重合——關聯結構大致保真，照 Argyle 的標準會判「像」。但政黨、意識形態、性別的關聯被放大：silicon 世界比真實世界更「整齊」。

8.3 延伸觀察 (非論文方法，本次新增)

- 拒答有訊號：48 個拒答者中 43 人現實中根本沒投兩黨——模型不肯猜的，恰是真的沒有答案的人。拒答從缺陷改判為誠實。
- 整體藍移：silicon 世界的 Trump 得票率比真人低約 8 個百分點，31 個子群體有 28 組往藍偏；猜錯的 99 人中 78 人是「真人投 Trump、模型說 Biden」。
- 信心兩極化：90% 的機率擠在 0.05 以下或 0.95 以上，中間近乎真空；模型說「幾乎 0% 投 Trump」的那群人實際有 14% 投了 Trump。

8.4 GABRIEL 對照：換任務框架

同一個模型、同樣的 backstory 資訊，把任務從第一人稱模擬（「.....我投給」）換成第三人稱分類（「判斷這位選民投誰」，用 GABRIEL 的 classify 執行）：

- 分類框架整體更準（等覆蓋率公平比較後 0.923 對 0.905），且難分的格子改善最多：純獨立選民 0.46 → 0.64。
- 但分類框架把 206 人放進「無法判定」——準確率有一部分是棄權換來的，比較時必須做等覆蓋率對照。
- 結論：要模型下判斷，用分類的問法（Role 1）；要產生行為與文字，才用模擬（Role 3）。工具對任務，而非工具比高下。

九、結論與使用守則

核心問題：給模型八大特徵做 silicon sampling，產出的母體像不像真實母體？判決分三塊：

- 結構像——關聯地圖（什麼因素跟投票綁多緊）與各群體的紅藍排序，幾乎完美重現（分組比例相關 0.93）。
- 位置不像——整個 silicon 母體比真實母體藍了約 8 個百分點，且是整片平移，不是雜訊。
- 紋理太乾淨——政黨決定投票的程度被放大、性別差距被放大，真實世界的雜訊（跨黨投票、不按牌理的人）被抹平。

一句話：像一張比例正確、但整體染了色、又被修圖修過頭的地圖。

使用守則

- 可以拿來「比較」：A 組比 B 組更傾向什麼，可信。
- 不能拿來「讀數」：任何百分比本身都不可直接引用。
- 它低報混亂：需要估計「不按牌理的人有多少」時，不要用它。
- 「像不像」取決於用哪把尺：只看 Cramér's V 會說像，多看邊際分布會說偏——驗證永遠多把尺一起上。

附錄：程式檔案清單與執行順序

序	檔案	作用
1	anes2020_資料整理_教學版.py	原始檔 → 凍結分析檔 anes2020_study2_frozen.csv（另有稽核版 prepare_anes2020.py 輸出完整稽核報告）
2	pilot_b_gpt56.py / pilot_b_v2_gpt56.py	20 人 pilot：測 logprobs 上限、發現拒答、驗證 續寫指令（2×2 設計）
3	run_main_1000.py	正式生成：1,000 人機率讀出，斷點續跑 → silicon_1000_results.csv
4	analyze_validation.py	個體層驗證：一致率、kappa、混淆矩陣、分層 表、拒答分層、校準 → validation_report.txt
5	distribution_validation.py	分布層驗證（照論文）：Cramér's V 表與圖 → cramers_v_table.csv
6	gabriel_readout.py	GABRIEL 對照實驗：backstory 第三人稱分類與比 對 → readout_comparison_report.txt

序	檔案	作用
7	visualize_comparison.py / visualize_validation.py	圖表：跨代對照啞鈴圖、四格驗證總覽圖

執行環境：Python 3.10+，pandas、matplotlib、openai、openai-gabriel；環境變數 OPENAI_API_KEY。GABRIEL 為非同步函數，notebook 環境須以 await 呼叫。